

# Capitolo 1

## Introduzione

Negli ultimi anni gli smart contracts sono diventati una tecnologia sempre pi popolare, attirando l'attenzione di molte aziende e sviluppatori. Questo interesse giustificato dalle loro features innovative, come l'immutabilit, il fatto che vengano eseguiti in una blockchain ed la loro esecuzione automatica. Tutta questa attenzione viene confermata dal loro inserimento all'interno di una proposta di regolamentazione da parte dell'Unione Europea [?]. Gli Smart Contracts vengono considerati un sistema per promuovere la condivisione dei dati, con la certezza che le condizioni di condivisione dei dati vengano rispettate. Proprio questa garanzia che le condizioni vengano rispettate solleva quelle che sono le preoccupazioni principali legate a problemi di sicurezza negli Smart Contracts.

La pi grande piattaforma di Blockchain che permette l'esecuzione degli smart contracts Ethereum. Gli smart contracts di Ethereum sono scritti in Solidity, un linguaggio di programmazione Turing-completo ad alto livello. Tuttavia, la scrittura di smart contracts sicuri una sfida, in quanto anche piccoli errori possono portare a gravi conseguenze. Gli smart contracts sono immutabili e una volta pubblicati non possono essere modificati e questa loro caratteristica pu rilevarsi il loro principale punto debole. Infatti, qualsiasi errore o vulnerabilit presente in uno smart contract pu essere sfruttato da un attaccante per rubare fondi o causare altri danni.

Per questo motivo, diventa fondamentale per gli sviluppatori avere dei tool che permettano di rilevare automaticamente le vulnerabilit presenti negli smart contracts che sviluppano. Spesso, per risolvere questo task si fa riferimento a tecniche di analisi statica, che permettono di analizzare il codice sorgente o il bytecode di uno smart contract senza effettuarne l'esecuzione effettiva. Questo approccio consente di identificare potenziali problematiche senza la necessit di testare il codice in un ambiente reale, di contro per queste tecniche si rivelano essere molto lente e fanno troppo affidamento al riconoscimento di pattern conosciuti o si basano su dei set di regole predefinite, che possono non essere esaustive o non riconoscere nuove vulnerabilit.

Un'alternativa a queste tecniche l'utilizzo di tecniche di Machine Learning e Deep Learning. Queste tecniche permettono di rilevare le vulnerabilit presenti negli smart

contracts in maniera pi rapida e con una maggiore accuratezza rispetto alle tecniche di analisi statica. In questo campo, negli ultimi anni c' stato un notevole interesse e sono stati proposti diversi approcci che utilizzano tecniche di Machine Learning e Deep Learning per la rilevazione di vulnerabilit negli smart contracts. Questi approcci si basano sull'addestramento di modelli di Machine Learning e Deep Learning.

Questo lavoro di tesi si inserisce in questo contesto e propone un approccio basato su tecniche di Deep Learning utilizzando modelli basati sui Transformers per la rilevazione di vulnerabilit negli smart contracts. In particolare, questo lavoro ha l'obiettivo di costruire dei modelli che siano in grado di rilevare cinque classi di vulnerabilit:

- Access-Control
- Arithmetic
- Other
- Reentrancy
- Unchecked-Calls

Il contributo di questo lavoro consiste nel dimostrare l'utilizzo di modelli basati sui Transformers per la rilevazione di vulnerabilit negli smart contract. In particolare, sono stati impiegati i modelli BERT, DistilBERT e CodeBERT per la classificazione. Considerando che questi modelli presentano un limite di 512 token in input e che i contratti possono essere significativamente pi lunghi, stato sperimentato un approccio di segmentazione del testo in sottocontratti e successiva aggregazione o concatenazione degli stessi. Questi modelli sono stati addestrati sia utilizzando il bytecode sia il codice sorgente dei contratti.

Inoltre, data la crescente diffusione di chatbot e assistenti virtuali nelle nostre vite, sia per il supporto a compiti di vario genere sia come ausilio alla programmazione, stato testato il modello Gemini di Google per valutare la sua performance in un task di classificazione di questo tipo. I risultati ottenuti da questo modello non sono stati soddisfacenti, evidenziando come per task di questo genere sia necessario utilizzare modelli specificamente addestrati.

I risultati ottenuti mostrano come questi modelli siano in grado di rilevare le vulnerabilit presenti negli smart contracts con delle ottime performance. In particolare, il modello CodeBERT, un modello preaddestrato su codice sorgente, ha ottenuto i risultati migliori, sia classificando il codice sorgente che classificando il codice bytecode in esadecimale. I migliori risultati, con un F1 Score dell'88% sono stati ottenuti dal modello CodeBERT che classificava il codice sorgente aggregando con la funzione max tre blocchi da 512 tokens. I migliori risultati classificando il bytecode sono stati sempre ottenuti dal modello

CodeBERT che classificava solo i primi 512 token della sequenza con un F1 score dell'83%.

La suddivisione di questo lavoro è articolata come segue:

- il capitolo due illustra le motivazioni alla base del presente lavoro di tesi, introducendo il concetto di smart contract e sottolineando l'importanza della rilevazione delle vulnerabilità in essi presenti. Verranno inoltre descritte alcune delle principali classi di vulnerabilità riscontrabili negli smart contract. Successivamente, sarà presentata una revisione della letteratura esistente in questo campo, con una panoramica dei lavori più significativi che hanno trattato questo tema.
- il terzo capitolo espone la metodologia adottata in questo lavoro. Inizialmente, sarà condotta un'analisi esplorativa del dataset. Successivamente, saranno introdotti i modelli utilizzati, BERT, DistilBERT e CodeBERT, con una dettagliata descrizione delle loro architetture e delle modalità di addestramento. Saranno illustrate le implementazioni e il setup dei vari esperimenti condotti. Inoltre, in questo capitolo sarà presentato il modello Gemini di Google e verrà spiegato come è stato applicato nel contesto di questo studio.
- il quarto capitolo riporta i risultati ottenuti nel corso del lavoro. Saranno presentate le performance dei vari modelli addestrati, valutate in termini di accuratezza, precisione, recall e F1 score. Infine, saranno mostrati i risultati ottenuti con il modello Gemini di Google.
- il quinto ed ultimo capitolo riporta le conclusioni del lavoro svolto, con una discussione dei risultati ottenuti e delle possibili direzioni future di ricerca.